

## חלק 1: מבוא

### רקע כללי

שביעות רצון מטופלים היא אחד המדדים המרכזיים להערכת איכות שירותי הבריאות, במיוחד במוסדות פסיכיאטריים שבהם תנאי האשפוז והיחס מצד הצוות הרפואי משפיעים ישירות על חוויית המטופל. הבנת הגורמים המשפיעים על שביעות הרצון יכולה לשמש ככלי לשיפור תנאי האשפוז, הטיפול וההתאמות הנדרשות לכל מטופל.

### מטרת המחקר

מטרת הפרויקט היא **לנתח את רמות שביעות הרצון של מטופלים בבתי חולים פסיכיאטריים באמצעות למידת מכונה, ולחלק אותם לקבוצות על פי שביעות רצונם**. לאחר החלוקה, ננסה **לאפיין את ההבדלים בין הקבוצות**, לזהות את הגורמים המשפיעים ביותר על שביעות הרצון ולבסוף להציע מודל שיכול לחזות את רמת שביעות הרצון של מטופלים חדשים.

## חלק 2: תיאור הדאטה והתכונות

### מקור הנתונים

הנתונים נאספו מסקרי שביעות רצון של מטופלים בבתי חולים פסיכיאטריים. כל שאלה בסקר מתייחסת להיבט אחר של חוויית האשפוז, כולל תנאים פיזיים, יחס הצוות הרפואי, איכות הטיפול והשירותים הנלווים. בנוסף, הדאטה מכיל מידע דמוגרפי כמו גיל, מגדר, בית חולים ומחלקה, לצד נתונים על משך האשפוז ומספר האשפוזים הקודמים של המטופל.

### שלבי עיבוד הנתונים

בשלב עיבוד הנתונים בוצעו מספר פעולות לשיפור איכות הנתונים ולהכנתם לניתוח. תחילה בוצע **ניקוי הנתונים**, שכלל הסרת עמודות כפולות ולא רלוונטיות, זיהוי וטיפול בערכים חסרים, והתמודדות עם ערכים חריגים. ערכים חסרים הושלמו במקרים מסוימים תוך שימוש במדדים סטטיסטיים כמו חציון והתפלגויות, או שהוסרו כאשר לא ניתן היה לבצע השלמה אמינה.

משום שסקאלת השאלות בסקר נעה בין טווחים שונים (למשל 1-5, 1-6, 1-10), **בוצע נרמול לערכים המספריים באמצעות MinMaxScaler** שהביא את כל הערכים לטווח של 0 עד 1. פעולה זו נועדה למנוע הטיות בתהליך הקלאסטינג או בחיזוי. משתנים קטגוריאליים קודדו בשיטת **One-Hot Encoding**, כדי לאפשר למודלים ללמוד מהם מבלי להניח סדר בין הקטגוריות.

**טיפול בערכי "לא יודע"** היה שלב חשוב נוסף. מכיוון שערכים אלו אינם ניתנים לפרשנות ישירה כציונים רגילים, הם קיבלו **ערך של 0.5**, על מנת לשמור על ניטרליות בניתוח. בנוסף, עמודות מסוימות שבהן סולם הציונים היה הפוך (למשל כאשר ציון 1 היה "מסכים מאוד" וציון 5 היה "לא מסכים"), עברו תיקון כך שהכיוונית תהיה עקבית, וציונים גבוהים תמיד ייצגו שביעות רצון גבוהה יותר.

במסגרת ההכנה לניתוח, נוספו משתנים חדשים כדי לספק מידע נוסף על המטופלים, כגון **חישוב ימי האשפוז של כל חולה**, חלוקה לקטגוריות גיל (age\_bins) ויצירת משתנה שבודק **האם חולה אושפז ברצון אך טופל בכפייה**.

## חלק 3: מתודולוגיה

### למידה בלתי מופקת – קלאסטינג (Clustering)

השלב הראשון של ניתוח הנתונים התמקד בחלוקת המטופלים לקבוצות על בסיס שביעות רצונם באמצעות טכניקות קלאסטינג. מטרת שלב זה הייתה לזהות קבוצות מובחנות של מטופלים ולנתח את ההבדלים ביניהן, תוך שימוש במדדים מתאימים לבחינת איכות הקלאסטרם.

#### תהליך הקלאסטינג

תחילה בוצעה בדיקה של מספר הקלאסטרם האופטימלי באמצעות שיטות שונות, כולל ניתוח גרפי של שיטת המרפק ומדדים סטטיסטיים כמו מדד Silhouette ומדד Davies-Bouldin. לאחר קביעת מספר הקלאסטרם, בוצעה השוואה בין מספר אלגוריתמים שונים, תוך ניתוח היתרונות והחסרונות של כל אחד.

לאחר בחירת האלגוריתם המתאים, בוצע אפיון של כל קלאסטר באמצעות ניתוח ממוצעים של תשובות הסקר והשוואת המשתנים הדמוגרפיים בין הקבוצות. ניתוח זה אפשר לזהות את ההבדלים המשמעותיים ביותר בין הקבוצות ולסווג אותן לקבוצה המרוצה יותר ולקבוצה הפחות מרוצה.

---

### למידה מופקת – חיזוי קלאסטרם (Classification)

לאחר סיווג המטופלים לקבוצות באמצעות קלאסטינג, השלב הבא התמקד בפיתוח מודל חיזוי המסוגל לשייך מטופלים חדשים לקלאסטרם שנוצרו. מטרת החיזוי הייתה למנוע פספוס של מטופלים המשתייכים לקלאסטר 1 (המייצג מטופלים פחות מרוצים), ולכן Recall עבור קלאסטר 1 נבחר כמדד המרכזי להערכת הביצועים. עם זאת, כדי למנוע מצב שבו המודל מסווג את כל המטופלים לקלאסטר 1, נעשה שימוש גם במדד **F1 Score** כדי להבטיח איזון בין Precision ל-Recall.

#### תהליך החיזוי

כדי לבחור את המודל המתאים ביותר למשימה, נבחנו 6 אלגוריתמים שונים: **LightGBM, XGBoost, Logistic Regression, Decision Tree, Random Forest, SVM**. כל המודלים הוערכו באמצעות **K-Fold Cross Validation** ובבדיקה יכולתם לזהות נכון מטופלים מקלאסטר 1.

לאחר השוואת הביצועים, נמצא כי **XGBoost השיג את ה-Recall הגבוה ביותר (0.78)** עבור קלאסטר 1, ולכן נבחר להמשך העבודה.

כדי לשפר את ביצועי המודל, בוצעה אופטימיזציה להיפר-פרמטרים באמצעות **GridSearchCV** וכן נבחר סף החלטה (**threshold=0.15**) לאחר ניסויים שונים כדי למקסם את ה-Recall.

המודל הסופי מאפשר כעת חיזוי של קלאסטרם עבור מטופלים חדשים על בסיס הנתונים הדמוגרפיים שלהם, דבר שיכול לשמש ככלי לקבלת החלטות לשיפור שביעות הרצון בבתי החולים.


## חלק 4: ניסויים ותוצאות

### קלאסטרינג (Clustering)


#### מספר הקלאסטרים:

הוחלט להשתמש ב,  $K=2$  לאחר בחינת מספר גישות לקביעת מספר הקלאסטרים:

- שיטת המרפק (Elbow Method): הצביעה על  $K=4$  כנקודת כיפוף.
- מדד סילואטה (Silhouette Score): הצביע על  $K=2$  כחלוקה ברורה יותר עם הפרדה טובה יותר בין הקבוצות.
- מדד Davies-Bouldin: חיזק את הבחירה ב  $K=2$  בכך שהראה מדד נמוך יותר לעומת  $K=4$



- **PCA:** הראה כי עבור  $K=2$  הקלאסטרים מופרדים בצורה טובה יותר מבחינה גרפית.



### בחירת אלגוריתם הקלאסטרינג

נבחנו שלושה אלגוריתמים:

- **K-Means:** האלגוריתם שנבחר בזכות יציבותו והפרדת הקלאסטרים הברורה.
- **GMM:** לא סיפק חלוקה מובהקת ולכן לא נבחר.
- **DBSCAN:** סיווג כמות גדולה של נקודות כחריגות (1-), ולכן נזנח.

### השפעת הפרמטרים על התוצאות

- הבחירה ב  $K=2$  שיפרה את מדדי הסילואטה וההפרדה בין הקלאסטרים בהשוואה ל-  $K=4$ .

- DBSCAN לא הצליח להתמודד עם מבנה הנתונים, ולכן נזנח לאחר ניסיונות לשנות את הפרמטרים.

### ניתוח ואפיון הקלאסטרים

הקלאסטרים זהו קלאסטר "מרוצה" עם ממוצע שביעות רצון של 0.8 לעומת קלאסטר "פחות מרוצה" עם ממוצע של 0.58.

### אפיון דמוגרפי של הקלאסטרים

בניתוח הדמוגרפי בוצע מבחן T על הנתונים של כל קלאסטר ברמת בטחון של 95%.

1. **בתי חולים :** הבדלים בייצוג בתי החולים בין הקלאסטרים (לדוגמה אחוז החולים המרוצים מבית חולים ב"ש הוא 16% לעומת 4% בקרב הלא מרוצים. בבי"ח שער מנשה המגמה הפוכה, 20% לא מסך הלא מרוצים לעומת 8% מסך המרוצים).
2. **גודל בית החולים:** מטופלים בבתי חולים גדולים השתייכו בעיקר לקלאסטר הלא מרוצה.
3. **מגדר וגיל:** לא נצפה קשר מובהק בין מגדר החולה והגיל שלו.
4. **פריפריאליות:** מטופלים בבתי חולים בפריפריה נטו להשתייך לקלאסטר היותר מרוצה.
5. **שפת אם :** נמצא הבדל מובהק בשפת המטופל בין הקלאסים (לדוגמה דוברי ערבית נוטים להשתייך לקלאסטר המרוצה).
6. **מקום שחרור לאחר האשפוז:** לא נמצא הבדל מובהק בין מקום השחרור לאחר האשפוז (בית, הוסטל וכו') בין הקלאסים.

### שאלות ההבדל המשמעותיות ביותר

בניתוח השאלות זהו 5 השאלות עם ההפרש הגדול ביותר בין הקלאסטרים, המייצגות גורמים מרכזיים לשביעות רצון:

שאלה	הפרש ממוצע בין הקלאסטרים
האם היית שותף בהחלטות הטיפוליות במידה בה היית מעוניין?	0.33
האם הבנת את ההסברים על הטיפולים והתרופות שקיבלת מהרופאים במהלך האשפוז?	0.32
האם קיבלת מענה מהצוות המטפל לשאלות ולבקשות שלך, ללא צורך להתאמץ?	0.31
האם הצוות הכין אותך לקראת השחרור?	0.3
האם ניתן לך מספיק זמן לדון עם הרופא שלך על מצבך הרפואי והטיפול בכך?	0.3

## מסקנות:

- מעורבות המטופלים בהחלטות רפואיות היא גורם קריטי לשביעות רצונם.
- שיפור ההסברים על טיפולים ותרופות יוכל להגביר את תחושת הביטחון של המטופלים.
- שיפור הזמינות והנגישות של הצוות המטפל יכול לצמצם תחושת מאמץ מצד המטופלים.
- הכנה טובה יותר לשחרור ושיח פתוח עם הרופאים חשובים למעבר חלק מהאשפוז להמשך טיפול בקהילה.

ממצאים אלו יכולים לשמש את הנהלת המוסד הרפואי לצורך שיפור חוויית המטופלים, באמצעות חיזוק תקשורת פתוחה עם הצוות הרפואי, קידום מעורבות המטופלים בהחלטות הטיפוליות והבטחת מתן מענה ברור ומקיף לכל שאלה ובקשה.

נוסף על כך, נבדקה הקורלציה בין שאלות הסקר לבין ציון שביעות הרצון הכללית. השאלה שהציגה את הקורלציה הגבוהה ביותר עם ציון שביעות הרצון היא "כמה הרגשת שאתה מטופל בידיים טובות?" עם מתאם של 0.61, הרבה מעל השאלה השנייה בדירוג, שהציגה מתאם של 0.4 בלבד. נתון זה מצביע על כך שהגורם המשפיע ביותר על שביעות הרצון הכוללת של המטופלים הוא תחושת הביטחון והאמון בצוות המטפל, יותר מכל משתנה אחר שנבדק.

## למידה מונחית – חיזוי הקלאסטרים (Supervised Learning)

### מטרת החיזוי

מטרת החיזוי הייתה לסווג את המטופלים לקלאסטרים, תוך דגש על זיהוי מדויק של המטופלים בקלאסטר הפחות מרוצה (קלאסטר 1). בוצע K-Fold Cross-Validation (k=5) כדי לשפר את יציבות המודלים ולמנוע הטיה. הושם דגש על שילוב בין Recall גבוה ל F1-Score על מנת להבטיח זיהוי מדויק תוך מזעור ניבוי יתר (False Positives). הרציונל היה לזהות את המטופלים בעלי סבירות גבוהה יותר לחוסר שביעות רצון כדי שנוכל להתאים להם את התנאים המתאימים. "המחיר" שהיינו מוכנים לשלם הוא בחיזוי של חולה "מרוצה" כ"לא מרוצה".

### המודלים שנבדקו

נבחנו שישה מודלים: XGBoost, LightGBM, Random Forest, Decision Tree, Logistic Regression, SVM. כל מודל הוערך לפי מדדי Recall ו-F1.

- XGBoost נבחר כמוביל בזכות איזון טוב בין Recall (0.8) ל F1 (0.61), מה שמבטיח זיהוי טוב של קלאסטר 1 תוך שמירה על דיוק סביר.
- LightGBM הציג Recall גבוה יותר (0.86) אך F1 מעט נמוך יותר (0.6), מה שמעיד על פוטנציאל לניבוי יתר בקלאסטר 1.
- שאר המודלים (Random Forest, Logistic Regression, Decision Tree, SVM) סיפקו תוצאות נמוכות יותר בשני המדדים ולכן לא נבחרו.

---

## תוצאות החיזוי

- **XGBoost** השיג את הביצועים הטובים ביותר, עם שילוב של **Recall גבוה (0.8)** ו **F1-סביר (0.61)**.
- טבלת תוצאות המודלים:

מודל	Recall	F-1
XGBoost	0.8	0.61
LightGBM	0.86	0.6
Random Forest	0.5	0.55
Decision Tree	0.61	0.6
SVM	0.46	0.44
Logistic Regression	0.64	0.6

---

## מסקנות

1. **בחירה ב- XGBoost** בזכות איזון בין Recall גבוה ו F1-סביר, הוא מספק חיזוי טוב ומדויק ללא ניבוי יתר.
2. **התאמה ליעדים**: הדגש על ריקול ו F1-תומך במטרת החיזוי של זיהוי המטופלים הפחות מרוצים, עם מינימום טעויות.
3. **יישום עתידי**: המודל הנבחר מתאים ליישום בעולם האמיתי ככלי לתמיכה בקבלת החלטות.

## חלק 5: מסקנות והמלצות

### חלוקת משימות:

שנינו עבדנו ביחד על תהליך ניקוי הנתונים והעיבוד המקדים. לאחר מכן, עמית התמקד בחלק של הקלאסטינג בזמן ששקד עבד על החיזוי במקביל, בזמן העבודה הנפרדת התייעצנו אחד עם השני והצגנו תוצרי ביניים.

### מסקנות עיקריות

#### 1. למידה בלתי מופקחת – קלאסטינג:

- קלאסטר אחד זוהה כ"מרוצה" עם ממוצע שביעות רצון של 0.8 בעוד השני כ"פחות מרוצה" עם ממוצע של 0.58.
- שאלות הנוגעות לצוות הטיפול והשירותים הנלווים נמצאו כמשפיעות ביותר על שביעות הרצון.
- ניתוח דמוגרפי העלה הבדלים מובהקים בין הקלאסטרים בחלק מהפרמטרים, למשל קלאסטר המרוצים היה נפוץ יותר בבתי חולים קטנים ופריפריאליים.

#### 2. למידה מונחית – חיזוי קלאסטינג:

- מודל XGBoost נבחר כמוביל בזכות Recall של 0.8 ו F1 של 0.61, שהבטיח זיהוי מיטבי של המטופלים הפחות מרוצים לצד דיוק סביר.

---

### המלצות

#### 1. שיפור חוויית המטופלים:

- להתמקד בנושאים בהם נמצאו הבדלים משמעותיים בין הקלאסטרים, כמו שביעות רצון מהצוות והשירותים הנלווים.
- לבחון פתרונות ממוקדים לשיפור התחומים שעלו בשאלות כמו q16, q5, q17.

#### 2. שימוש במודל החיזוי:

- לשלב את מודל XGBoost ככלי תומך החלטות לזיהוי מוקדם של מטופלים פחות מרוצים ולמנוע ירידה באיכות השירות.

#### 3. תחזוקה והרחבה:

- לעדכן את המודל בהתאם לשינויים בנתונים ולנתח את ביצועיו באופן שוטף.
- לשלב משתנים חדשים, כמו שביעות רצון ממעקב לאחר שחרור, ולבצע מחקרים משווים עם מוסדות רפואיים אחרים.

### סיכום

הדו"ח מספק כלים מבוססי נתונים לשיפור שביעות רצון המטופלים ומציע כיוונים לפיתוח שירותים מותאמים יותר לצורכי המטופלים. קישור ל-GitHub.